

Sistem de recunoaștere a indicatoarelor rutiere bazat pe analiza formelor

Autori:

- Antal Simona
- Lisei Larisa-Claudia

1. Introducere

Proiectul abordează problema detectării și recunoașterii unui set restrâns de indicatoare rutiere sau simboluri imprimate în imagini și secvențe video scurte, în condiții variabile de scară, rotație și iluminare.

2. Soluția și implementarea propuse




Fig. 1. Pipeline-ul aplicației

Preprocesarea imaginilor realizează redimensionarea și egalizarea histogramei. Ulterior, sistemul combină segmentarea bazată pe culoare (roșu, albastru, galben) cu detecția muchiilor, astfel încât formele indicatoarelor să poată fi identificate mai robust. Rezultatele obținute din cele două metode sunt integrate și folosite în etapa de antrenare, iar performanța modelului este evaluată prin testare pe imagini separate. Implementarea a fost realizată în Python, folosind biblioteci precum OpenCV pentru procesarea imaginilor, NumPy pentru operații numerice și scikit-learn pentru antrenarea și evaluarea modelului.

Etapă	Metodă utilizată	Justificare
Egalizarea histogramei	CLAHE	Îmbunătățirea adaptivă a contrastului
Segmentare pe culoare	Măști HSV pentru R, B, Y	HSV separă separat informația de culoare de luminozitate

Etapă	Metodă utilizată	Justificare
Deteția muchiilor	Canny cu prag prin metoda Otsu	Evidențierea contururilor pentru dectia formelor
Deteția formelor	Aproximarea cu un poligon	Permite clasificarea formelor după numărul de vârfuri
Deteția cercurilor	Transformata Hough	Detectarea formelor circulare care nu sunt identificate ușor prin aproximarea poligonală
Extragerea caracteristicilor	Hu Moments + HOG + Histograma	Combină informații despre formă, structură vizuală și culoare
Clasificare	SVM cu kernel RBF	Potrivit pentru separarea datelor neliniare cu un hiperplan
Evaluare	Matrice de confuzie + acuratețe totală și per clasă	Permite măsurarea performanțelor modelului pe datele de test

Tabel 1. Metode implementate

3. Experimente și rezultate

Dataset-ul utilizat conține 43 de clase cu semne de circulație, fiecare cu 40–200 de imagini, capturate în condiții variate de iluminare și perspectivă. Deși analiza formei este realizată pe patru categorii geometrice principale (cerc, patrulater, triunghi și octogon), clasificarea finală urmărește identificarea semnului rutier specific, în funcție de cele 43 de clase disponibile. Pentru evaluarea performanței, datele din fiecare clasă au fost împărțite separat în 80% pentru antrenare și 20% pentru testare, astfel încât toate cele 43 de clase să fie reprezentate echilibrat în ambele seturi.

Metrică	Rezultat
Acuratețe	0.8951
Eroare de clasificare	0.1049
Eroare medie pătratică	8.5588

Tabel 2. Rezultate finale

Formă	Hits	Total
Cerc	421	452
Patrulater	19	24
Triunghi	49	69
Octogon	6	8

Tabel 3. Rezultate per formă




Fig. 2. Matricea de confuzie pentru cele 43 de clase de indicatoare

3.1. Analiza cantitativă și/sau calitativă

Acuratețe	C	Gamma	Kernel
0.0242	0.1	0.001	poly
0.2222	1	0.001	poly
0.5332	0.1	0.001	rbf
0.8280	10	0.01	rbf
0.9154	100	0.001	liniar
0.9186	100	0.001	rbf

Tabel 4. Analiza parametrilor pentru SVM

3.2. Studiu comparativ

Versiune	Ce a fost implementat	Îmbunătățiri	Limitări
Experiment 1	Segmentare culoare și detecția formei prin aproximarea poligonală		Cercurile și octogonele sunt confundate des

Experiment 2	Deteție cercuri cu metoda Hough	Cercurile sunt detectate separat	Dacă forma este obturată nu va fi detectată
Experiment 3	Segmentare culoare + Canny	Forme detectate mai bine, se combină rezultatele	Dacă nu e identificată culoarea conturului, Canny nu ajută
Final	Clasificare cu SVM folosind și Hu Moments, HOG și Histograma	Deteție după cele 43 de clase, nu doar după formă	Unele obiecte pot fi clasificate greșit dacă nu sunt eliminate în faza de segmentare

Tabel 5. Compararea versiunilor aplicației

4. Concluzii

Proiectul a demonstrat că indicatorii rutiere pot fi recunoscuți eficient prin combinarea analizei formei, culorii și descriptorilor vizuali. Modelul SVM a obținut o acuratețe bună pentru cele 43 de clase, în special pentru formele circulare, care sunt mai bine reprezentate în dataset. Principalele limitări apar în cazul imaginilor cu iluminare slabă, semne parțial obturate sau clase cu forme și culori similare.